YOLOv8 추론 & Kalman Filter 개요

Day5 · 블록2

cchyun@gmail.com

Part 1. 객체 탐지와 YOLOv8 개념

객체 탐지(Object Detection)란?

- **로봇이 세상을 이해하기 위한 핵심 기술 — "로봇의 눈"**
  - **이미지 분류(Classification)**
    - "이 사진 속에 무엇이 있는가?"에 집중
    - 예: "이것은 '사람'이다" — 한 단어로 정의
  - **객체 탐지(Object Detection)**
    - **"무엇이 어디에 있는가?"** 를 동시에 해결
    - 사진 속 물체를 찾아내고 위치를 사각형 박스로 표시
  - **로봇 관점에서의 차이**
    - 분류: "앞에 장애물이 있다" (위치 모름)
    - **탐지: "장애물이 왼쪽 2미터 지점에 있다"** (위치 + 종류)
    - 로봇 주행 시 탐지 정보가 훨씬 중요

객체 탐지(Object Detection)란?

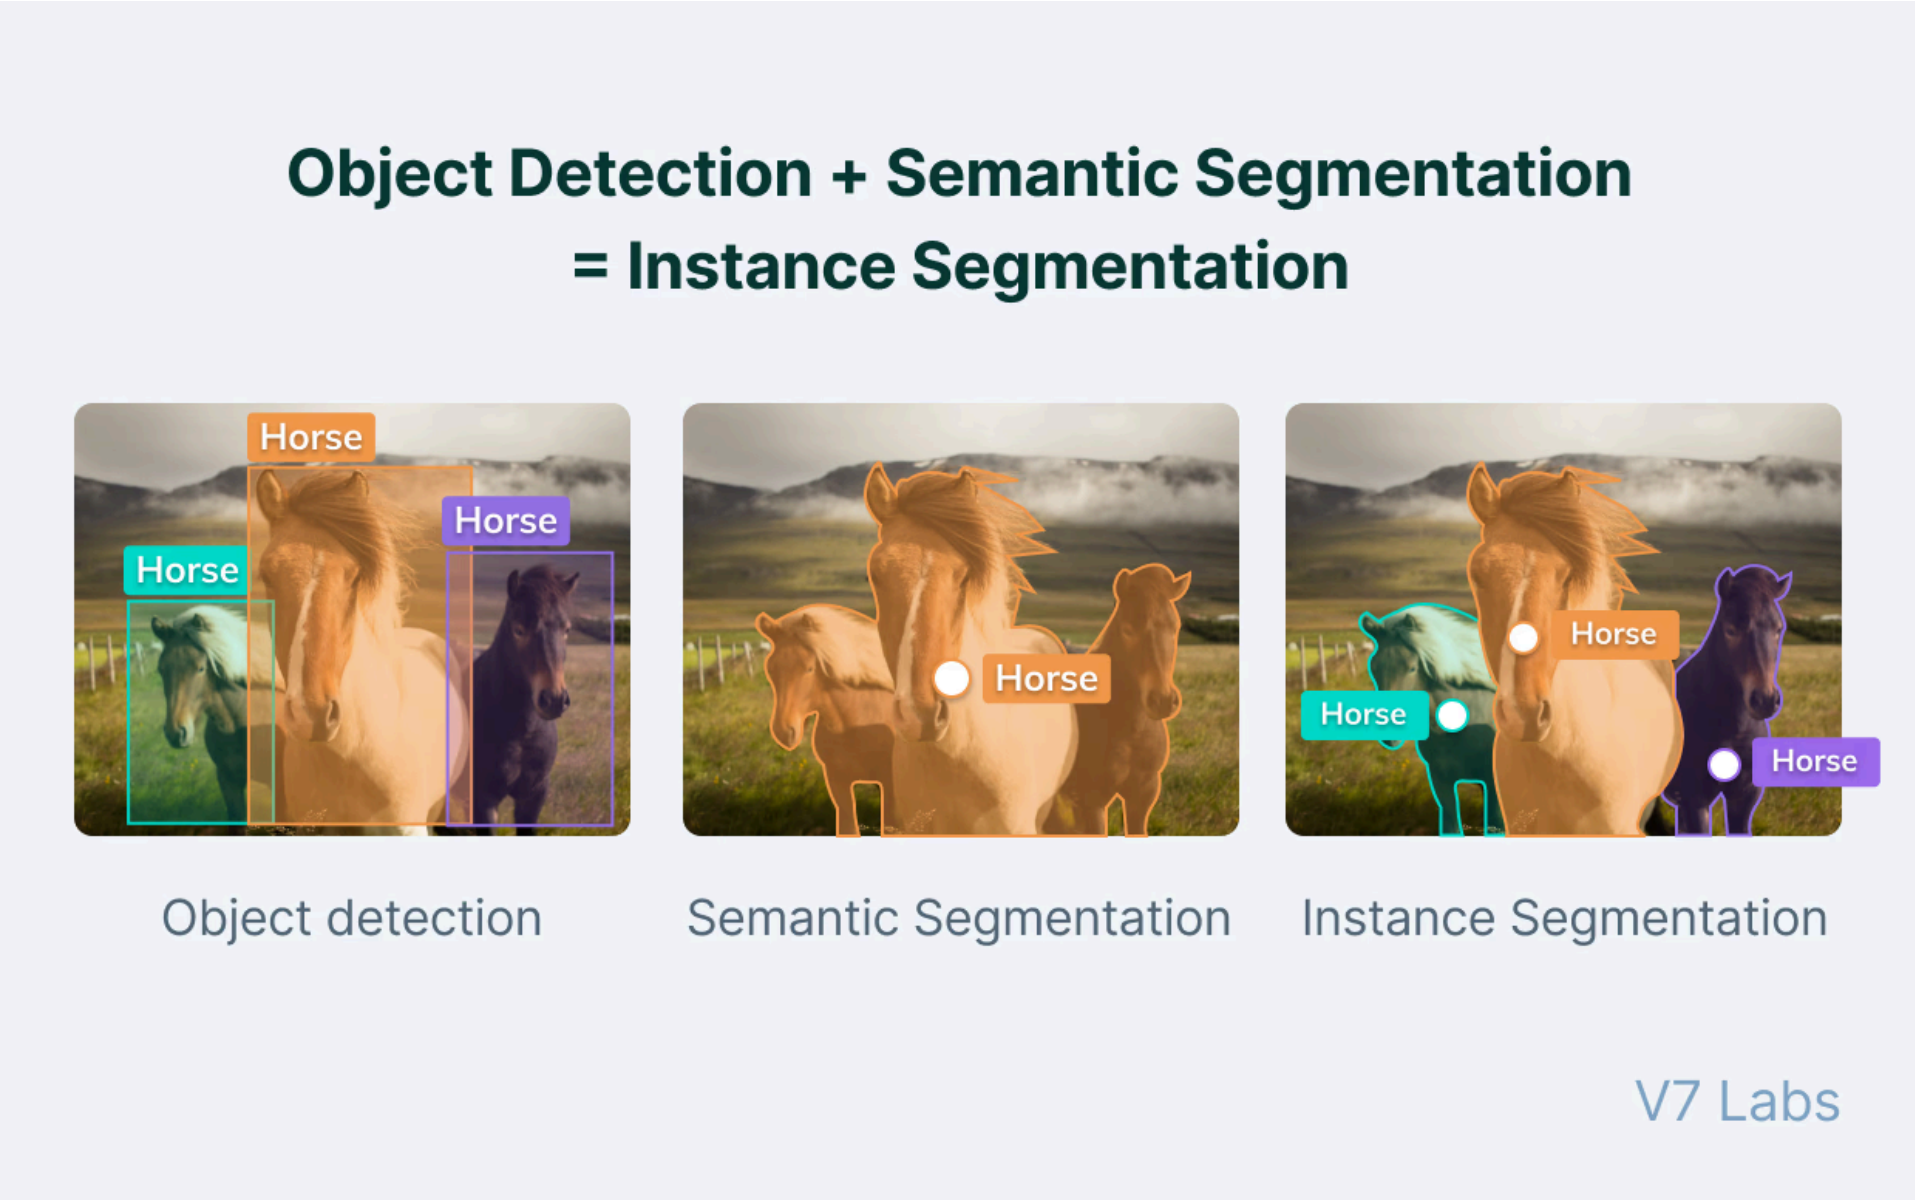

https://www.v7labs.com/blog/object-detection-guide

객체 탐지 모델 구조: 1-Stage vs 2-Stage

- **탐지 방식에 따라 두 가지 계열로 구분**

구분	1-Stage (단일 단계)	2-Stage (두 단계)
대표 모델	YOLO, SSD, RetinaNet	Faster R-CNN, Mask R-CNN
동작 방식	위치 + 분류를 **한 번에** 예측	후보 영역 추출 → 분류 **순차 처리**
속도	빠름 (실시간 가능)	느림 (배치 처리에 적합)
정확도	상대적으로 낮음	상대적으로 높음
주요 용도	로봇, 자율주행, 엣지 장치	의료 영상, 정밀 검사

객체 탐지 모델 구조: 1-Stage vs 2-Stage

- **2-Stage 방식의 두 단계**
  - **1단계 — RPN (Region Proposal Network)**
    - 물체가 있을 법한 후보 영역(Anchor Box)을 수천 개 제안
  - **2단계 — Classification**
    - 후보 영역 각각을 분류 → 높은 정확도, 높은 연산 비용

- **로봇 개발에서 1-Stage를 선택하는 이유**
  - 실시간 제어 루프(30 FPS 이상)에서 지연 시간 최소화가 핵심
  - 라즈베리 파이 등 **엣지 장치**에서 2-Stage는 사실상 실시간 불가

YOLO의 핵심 아이디어: "You Only Look Once"

- **YOLO(욜로): "단 한 번만 본다"**
  - **기존 방식의 문제점**
    - 이미지에서 물체가 있을 법한 곳을 **수천 번** 훑어본 뒤 판단
    - 처리 속도가 느려 실시간 적용 어려움
  - **YOLO의 혁신적 방식**
    - 이미지를 격자(Grid)로 나눈 뒤
    - 신경망이 이미지 전체를 **단 한 번의 평가(Evaluation)** 만으로
    - 모든 사각형 박스와 물체 종류를 **동시에 예측**
  - **핵심 장점: 매우 빠름**
    - 로봇처럼 실시간 즉각 판단이 필요한 장치에 최적화

YOLO 버전 역사 — 주요 이정표

- **2015년 등장 이후 다양한 팀이 발전시켜 온 실시간 탐지의 표준**

버전	연도	개발	핵심 변화
v1	2015	Redmon et al.	Grid 기반 1-Stage 탐지, 45 FPS 실시간 처음 구현
v2	2016	Redmon et al.	Anchor Box 도입, Batch Normalization, Darknet-19
v3	2018	Redmon et al.	다중 스케일 탐지(3단계), Darknet-53, 소형 객체 성능↑
v4	2020	Bochkovskiy et al.	Bag of Freebies, IoU 손실 함수, CSPNet 백본
v5	2020	Ultralytics	최초 PyTorch 구현, 자동 Anchor 학습, 생산 환경 최적화
v8	2023	Ultralytics	Anchor-free, C2f 블록, 탐지·분할·자세추정 통합
v9	2024	Wang et al.	PGI(기울기 정보 보존), GELAN 아키텍처
v10	2024	칭화대	NMS-free 추론, One-to-One 헤드 구조
v11	2024	Ultralytics	C3k2·C2PSA 블록, 소형 객체 정확도↑, 엣지 최적화
v12	2025	Tian et al.	Attention 중심 설계(Area Attention), NMS-free, 낮은 지연·높은 mAP

YOLO 세대별 핵심 흐름

- **1세대 — 개념 정립 (v1 ~ v3, 2015~2018)**
  - Joseph Redmon이 설계한 원조 YOLO
  - "이미지를 단 한 번만 본다"는 1-Stage 패러다임 확립
  - v3에서 다중 스케일 탐지로 소형 객체 한계 극복

- **2세대 — 커뮤니티 주도 (v4 ~ v7, 2020~2022)**
  - Redmon이 군사 적용 우려로 연구 중단 → 커뮤니티가 이어받음
  - Ultralytics의 v5가 PyTorch 기반으로 대중화에 결정적 기여
  - v4~v7은 정확도·속도 미세 최적화에 집중

- **3세대 — 다목적 통합 (v8 ~ v12, 2023~2025)**
  - 탐지 단일 모델 → **탐지 + 분할 + 자세 추정 + 분류** 단일 코드베이스
  - Anchor-free 설계가 표준으로 정착
  - v10·v11에서 **NMS-free** 구조로 엣지 장치 지연 시간 최소화
  - v12(2025.02)는 **Attention 중심 아키텍처**로 전환 — Area Attention 모듈로 기존 CNN 위주 설계에서 벗어나 정확도·속도 동시 개선

YOLOv8 주요 개선 사항

- YOLOv8
  - **정확도와 속도 향상**
    - 더 정교한 설계(C2f 블록 등)
    - 이전보다 적은 계산량으로 더 정확한 물체 감지
  - **사용자 친화적 (Python-native)**
    - 복잡한 설정 파일 없이 Python 코드 몇 줄로 바로 실행
    - 입문자도 쉽게 시작 가능
  - **다양한 기능 — 단일 코드베이스**
    - **탐지(Detection):** 물체의 위치와 종류 파악
    - **분할(Segmentation):** 물체의 형태를 픽셀 단위로 추출
    - **자세 추정(Pose):** 사람의 관절 위치 파악

Part 2. YOLOv8 설치 및 기본 사용법

설치 및 사전 학습 모델 선택

- **설치 — 명령어 하나로 완료**

```
pip install torch torchvision --index-url https://download.pytorch.org/whl/cpu
pip install ultralytics numpy==1.26.4 opencv-python==4.10.0.84
```

YOLOv8 실행에 필요한 모든 라이브러리가 설치됨

- **사전 학습 모델(Pre-trained Models) — 로봇 성능에 맞춰 선택**

종류	특징	권장 환경
n (Nano)	가장 빠르고 가벼움	라즈베리 파이, 젯슨 나노 등 소형 로봇
s (Small)	속도와 정확도의 균형	일반적인 자율주행 로봇
m (Medium)	높은 정확도	고성능 PC 탑재 산업용 로봇
l/x (Large/X-Large)	최고 정확도, 느림	연구용, 복잡한 장면 분석

이미지/영상 추론 예제 코드

- **로봇 주행 시나리오(사람/장애물 탐지) 기본 코드**

```
from ultralytics import YOLO
import cv2

# 1. 모델 로드 (가장 가벼운 Nano 모델 사용)
model = YOLO('yolov8n.pt')

# 2. 이미지 파일에서 추론
results = model.predict(source='robot_view.jpg', save=True)

# 3. 실시간 카메라(웹캠) 스트리밍 추론 (로봇 주행 시 사용)
# source=0은 기본 카메라를 의미
model.predict(source=0, show=True)
```

- `source`에는 이미지 파일 경로, 동영상 파일, 실시간 카메라 번호 입력 가능

추론 결과 해석 — 주요 데이터 항목

- `results` 객체에서 핵심 데이터 추출
  - **Bounding Box (xyxy)**
    - 물체의 위치: `[x1, y1, x2, y2]` 형태
    - 왼쪽 상단과 오른쪽 하단의 좌표
  - **신뢰도(Confidence)**
    - 0 ~ 1 사이의 값
    - "이것이 사람일 확률이 얼마나 높은가?"
    - 보통 **0.5(50%) 이상**일 때만 진짜로 인식
  - **클래스(Class)**
    - 찾은 물체의 번호
    - 예: 0번 = '사람', 2번 = '자동차'

데이터 추출 코드 예시

```python
results = model('robot_view.jpg')
for result in results:
    boxes = result.boxes  # 상자 정보들
    for box in boxes:
        # 좌표 (좌상단 x, y, 우하단 x, y)
        x1, y1, x2, y2 = box.xyxy

        # 신뢰도 점수
        conf = box.conf

        # 클래스 번호
        cls_id = int(box.cls)

        # 물체 이름 확인 (예: person, bicycle...)
        label = model.names[cls_id]

        print(f"발견: {label}, 위치: ({x1}, {y1}), 확률: {conf:.2f}")
```

- **로봇 제어 로직 예시**
  - `label == 'person'` 이고 `conf > 0.5` 이면 → **"긴급 정지"** 명령

결과 시각화 & Troubleshooting

- **결과 시각화 — 코드 한 줄로 완료**

```
annotated_frame = results.plot()  # 박스, 이름, 확률 자동으로 그림
cv2.imshow("Robot Vision", annotated_frame)
cv2.waitKey(0)
cv2.destroyAllWindows()
```

- **입문자가 자주 하는 실수**
  - **CPU vs GPU 문제:** GPU(NVIDIA) 없으면 수십 배 느림 — 설치 시 CUDA 버전 확인
  - **경로 오류:** 모델 파일/이미지 파일이 코드와 같은 폴더에 있어야 함
  - **이미지 크기 미조정:** `imgsz=320` 옵션으로 속도 향상 가능 (기본값 640)
  - **카메라 번호 혼동:** 카메라가 여러 대라면 `source=0` 이 아닌 `1`, `2` 일 수 있음

Part 3. YOLOv8 실전 활용 + 최적화

실시간 웹캠 추론 파이프라인

```python
import cv2
from ultralytics import YOLO

model = YOLO('yolov8n.pt')  # Nano 모델이 속도가 가장 빠름
cap = cv2.VideoCapture(0)   # 0은 기본 웹캠

while cap.isOpened():
    success, frame = cap.read()
    if not success:
        break

    # stream=True 옵션은 메모리 효율적인 제너레이터를 반환
    results = model.predict(frame, stream=True)

    for r in results:
        annotated_frame = r.plot()  # OpenCV 호환 배열 반환
        cv2.imshow("YOLOv8 Real-time Inference", annotated_frame)

    if cv2.waitKey(1) & 0xFF == ord('q'):  # 'q' 키로 종료
        break

cap.release()
cv2.destroyAllWindows()
```

탐지 결과 필터링

- **Confidence Threshold 조절**
  - `model.predict(conf=0.5)` 로 낮은 확률의 거짓 양성(False Positive) 제거

- **특정 클래스만 탐지**
  - YOLOv8은 COCO 데이터셋의 80개 클래스 기본 지원
  - `classes` 매개변수로 원하는 클래스 인덱스만 지정

```
model.predict(classes=[0, 2])  # 사람(0)과 자동차(2)만 탐지
```

- **NMS (Non-Maximum Suppression)**
  - 하나의 객체에 여러 경계 상자 생성 시, 가장 높은 점수만 남기고 나머지 제거
  - 각 상자 간의 **겹침 정도(IoU)** 를 계산하여 임계값 이상 겹치는 상자 삭제
  - 최신 YOLO 버전(YOLO10 등)은 NMS-free 아키텍처 채택

추론 속도 최적화 — 모델 크기 선택

- **프로젝트 요구사항에 따른 Trade-off**

모델	속도 (GPU)	파라미터 수	주요 용도
YOLOv8n (Nano)	~1.0 ms	3.2M	모바일, 엣지 장치, 초고속 탐지
YOLOv8s (Small)	~2.5 ms	11.2M	일반적인 로봇 픽앤플레이스
YOLOv8m (Medium)	~6.0 ms	25.9M	복잡한 산업 검사
YOLOv8x (X-Large)	~15.0 ms	68.2M	고정밀 연구, 복잡한 장면

- **추가 최적화 방법**
  - **이미지 해상도 조절:** `imgsz` 낮추면 속도↑, 소형 객체 탐지 성능↓
  - **GPU 활용:** NVIDIA CUDA 지원 GPU에서 수십 배 빠름 (실시간 로봇 필수)
  - **엣지 최적화:** Intel OpenVINO, ONNX, TensorRT 변환 + FP16/INT8 양자화

성능 문제와 해결법

- **지연 시간(Latency) 누적**
  - **문제:** 처리가 입력 속도보다 느려 화면이 밀리는 현상
  - **해결:** `model.predict(stream=True)` 로 제너레이터 방식 처리, 최신 프레임만 사용

- **탐지 결과의 흔들림(Flickering)**
  - **문제:** 경계 상자가 프레임마다 미세하게 떨리는 현상
  - **해결: 칼만 필터(Kalman Filter)** 도입 — 이전 프레임 기반 예측 및 보정

- **엣지 장치(Raspberry Pi 등) 성능 저하**
  - **문제:** CPU 점유율 100%, 1~2 FPS 수준
  - **해결:** 모델을 **ONNX** 또는 **TensorRT** 형식으로 내보내기(Export), 양자화 적용

ROS2 토픽 퍼블리시를 위한 데이터 구조 설계

- **로봇 시스템에서 탐지 결과를 다른 노드로 전달**
  - `sensor_msgs/Image` 를 입력받아 `vision_msgs` 형태로 퍼블리시

- **추천 데이터 구조**
  - **Header:** 타임스탬프 및 프레임 ID (TF2 좌표 변환에 필수)
  - **Detections (리스트):**
    - `class_id` (int): 객체 종류
    - `confidence` (float): 신뢰도
    - `bbox` (float[4]): [x_center, y_center, width, height] (픽셀 좌표)

- **ROS2 통합 팁**
  - `cv_bridge` 를 사용하여 ROS2 이미지 메시지 → OpenCV(NumPy 배열) 변환
  - 변환 후 YOLO 처리 수행

Part 4. Kalman Filter 개념 개요

칼만 필터가 왜 필요한가? — 노이즈 문제

- **모든 센서에는 '노이즈(Noise)'라는 방해꾼이 존재**

  - **GPS 센서 (측정치)**
    - 로봇의 현재 위치를 알려주지만 정확도가 떨어짐
    - 실제 위치에서 10m 정도 왔다 갔다 → 이 데이터만 믿으면 **지그재그 이동**

  - **로봇의 계산 (예측치)**
    - 바퀴 회전 수로 "나는 지금쯤 어디 있겠구나" 추측
    - 하지만 바퀴가 헛돌거나 바람에 밀릴 수 있어 **완벽하지 않음**

  - **칼만 필터의 역할**
    - **불안정한 센서 데이터(GPS) + 불완전한 내 추측(바퀴 회전수)**
    - → 적절히 융합하여 **실제 위치에 가장 가까운 값**을 실시간으로 계산

https://www.bzarg.com/p/how-a-kalman-filter-works-in-pictures/
https://kr.mathworks.com/videos/understanding-kalman-filters-part-1-why-use-kalman-filters--1485813028675.html

핵심 아이디어: 예측(Predict)과 업데이트(Update)

- **칼만 필터는 두 단계를 끊임없이 반복하는 순환 구조**

  - **1단계: 예측 (Predict) — "어디로 갈 것인가?"**
    - 현재 속도와 방향으로 다음 순간의 위치를 **미리 짐작**
    - 비유: 날씨 예보 — "어제 기압과 바람을 보니 내일은 비가 올 것 같아"
    - 시간이 지날수록 **불확실성(오차 범위)이 커짐**

  - **2단계: 업데이트 (Update/Correct) — "실제로는 어디인가?"**
    - 새로운 센서 데이터가 들어오면 예측과 측정값을 비교·수정
    - 비유: 예보(비)였는데 창밖을 보니 구름만 → "흐림으로 수정"

  - **칼만 이득(Kalman Gain)**
    - 예측과 센서 중 무엇을 더 믿을지 결정하는 **가중치**
    - 센서가 정확하면 센서를 더 믿고, 센서가 튀면 예측을 더 믿음

로봇 개발에서의 칼만 필터 활용 사례

- **물체 추적 (YOLO 탐지 결과 안정화)**
  - YOLO 경계 상자(Bounding Box)가 미세하게 떨리는 현상 발생
  - 칼만 필터로 움직임을 **부드럽게(Smoothing)**
  - 물체가 잠시 가려져도 다음 위치를 **예측하여 추적 유지**

- **위치 추정 (GPS + IMU 융합)**
  - GPS: 절대 위치 제공, 느림
  - IMU(가속도/자이로): 빠르지만 오차 누적
  - 칼만 필터로 두 센서를 융합 → **빠르고 정확한 위치 정보**

- **속도 추정**
  - 위치 센서값만 있을 때
  - 시간에 따른 위치 변화를 계산하여 **현재 속도를 추정**

EKF (Extended Kalman Filter)란?

- **기본 칼만 필터의 한계와 확장**

  - **기본 칼만 필터의 가정**
    - 물체가 **직선으로 일정하게 움직이는 '선형 시스템'** 가정
    - 곡선 이동이나 복잡한 움직임에는 적용 어려움

  - **현실의 로봇 — '비선형 시스템'**
    - 커브를 돌거나 복잡한 움직임
    - 기본 칼만 필터를 직접 적용할 수 없음

  - **EKF의 해결 방법**
    - 복잡한 곡선 움직임을 순간순간 잘게 쪼개어
    - **직선처럼 취급(선형화)**
    - → 칼만 필터의 원리를 비선형 시스템에도 적용 가능

Part 5. 칼만 필터 — 원리 깊이 이해하기

상태(State)란 무엇인가?

- **칼만 필터가 추적하는 것 — 위치 p와 속도 v**

$$\vec{x} = \begin{bmatrix} p \\ v \end{bmatrix}$$

- **왜 속도도 함께 추적하는가?**
  - 위치만 알아서는 "다음에 어디 있을지" 모름
  - 속도를 알면 다음 위치를 **예측** 가능
  - 비유: 친구 차가 지금 서울에 있다는 것만 알면 1시간 뒤 위치를 모른다.
    하지만 **"서울에서 시속 100km로 부산 방향"** 이라면 예측 가능!

- **둘 다 정확한 값을 모른다** → 칼만 필터가 추정하는 대상
  - 추정값의 **중심** = $\hat{x}_k$ (가장 그럴듯한 값)
  - 추정값의 **불확실성** = P_k (얼마나 모르는지)

https://jonathan-hui.medium.com/self-driving-object-tracking-intuition-and-the-math-behind-kalman-filter-657d11dd0a90

불확실성을 숫자로 표현하기 — 분산

- **공분산 행렬 P_k — 2D 불확실성 표현**

$$P_k = \begin{bmatrix} \sigma_p^2 & \sigma_{pv} \\ \sigma_{vp} & \sigma_v^2 \end{bmatrix}$$

원소	의미
σ_p^2 (대각)	위치를 얼마나 모르는가
σ_v^2 (대각)	속도를 얼마나 모르는가
σ_{pv} (비대각)	위치 오차와 속도 오차가 얼마나 연결되어 있는가

- **P_k는 대칭행렬 — $\sigma_{pv} = \sigma_{vp}$**
  - "위치 오차와 속도 오차의 상관관계"는 어느 방향에서 봐도 동일

불확실성을 숫자로 표현하기 — 분산

- **아래 첨자 k의 의미 — 시간 스텝**
  - $k = 0, 1, 2, 3 \cdots$ = "몇 번째 시간 순간인가" (예: 매 0.1초마다 1씩 증가)
  - 한 스텝 안에서 Predict($\hat{x}_k^-$, P_k^-) → Update($\hat{x}_k$, P_k) 두 번 변함

```
k=1 진입 → Predict → x̂_k⁻, P_k⁻  (불확실성 증가)
        → Update  → x̂_k,  P_k   (불확실성 감소)
k=2 진입  (x̂_k, P_k 가 다음 스텝의 x̂_{k-1}, P_{k-1}이 됨)
```

- **초기값 P_0 — 사용자가 직접 설정**
  - 실제 오차를 계산하는 게 아니라 **"얼마나 모른다고 가정할지"** 를 설계자가 결정
  - 잘못 설정해도 몇 스텝 안에 현실적인 값으로 **자동 수렴**
  - 불확실하면 **크게** 설정하는 것이 안전

```
# "초기 위치는 ±5m, 속도는 ±2m/s 정도로 불확실하다" 고 가정
# 분산 = 표준편차² → 5² = 25, 2² = 4
P_0 = [[25, 0],
       [0,  4]]
```

노이즈 행렬 Q와 R — "무엇을 믿을 것인가"

	Q_k (프로세스 노이즈)	R_k (센서 노이즈)
의미	내 예측이 얼마나 틀릴 수 있는가	센서가 얼마나 부정확한가
비유	"바람이 세서 내 예측이 빗나갈 수 있어"	"GPS가 ±10m 오차야"
적용 단계	Predict	Update
설정 방법	설계자 경험으로 설정 (어려움)	센서 데이터시트 참조 (비교적 쉬움)
크기	상태변수 수 × 상태변수 수	**센서 수 × 센서 수**

- **R_k 크기는 센서 개수에 따라 결정됨**
  - GPS만 있을 때 → 1×1 스칼라
  - GPS + 속도계 → 2×2 행렬
  - YOLO 중심좌표 (x, y) → 2×2 행렬

```
# 센서를 고정하고 많이 측정 → 분산 = 노이즈 크기
readings = gps.measure(n=1000)
R = np.var(readings)    # GPS 노이즈 공분산 계산
```

Predict 전 상태

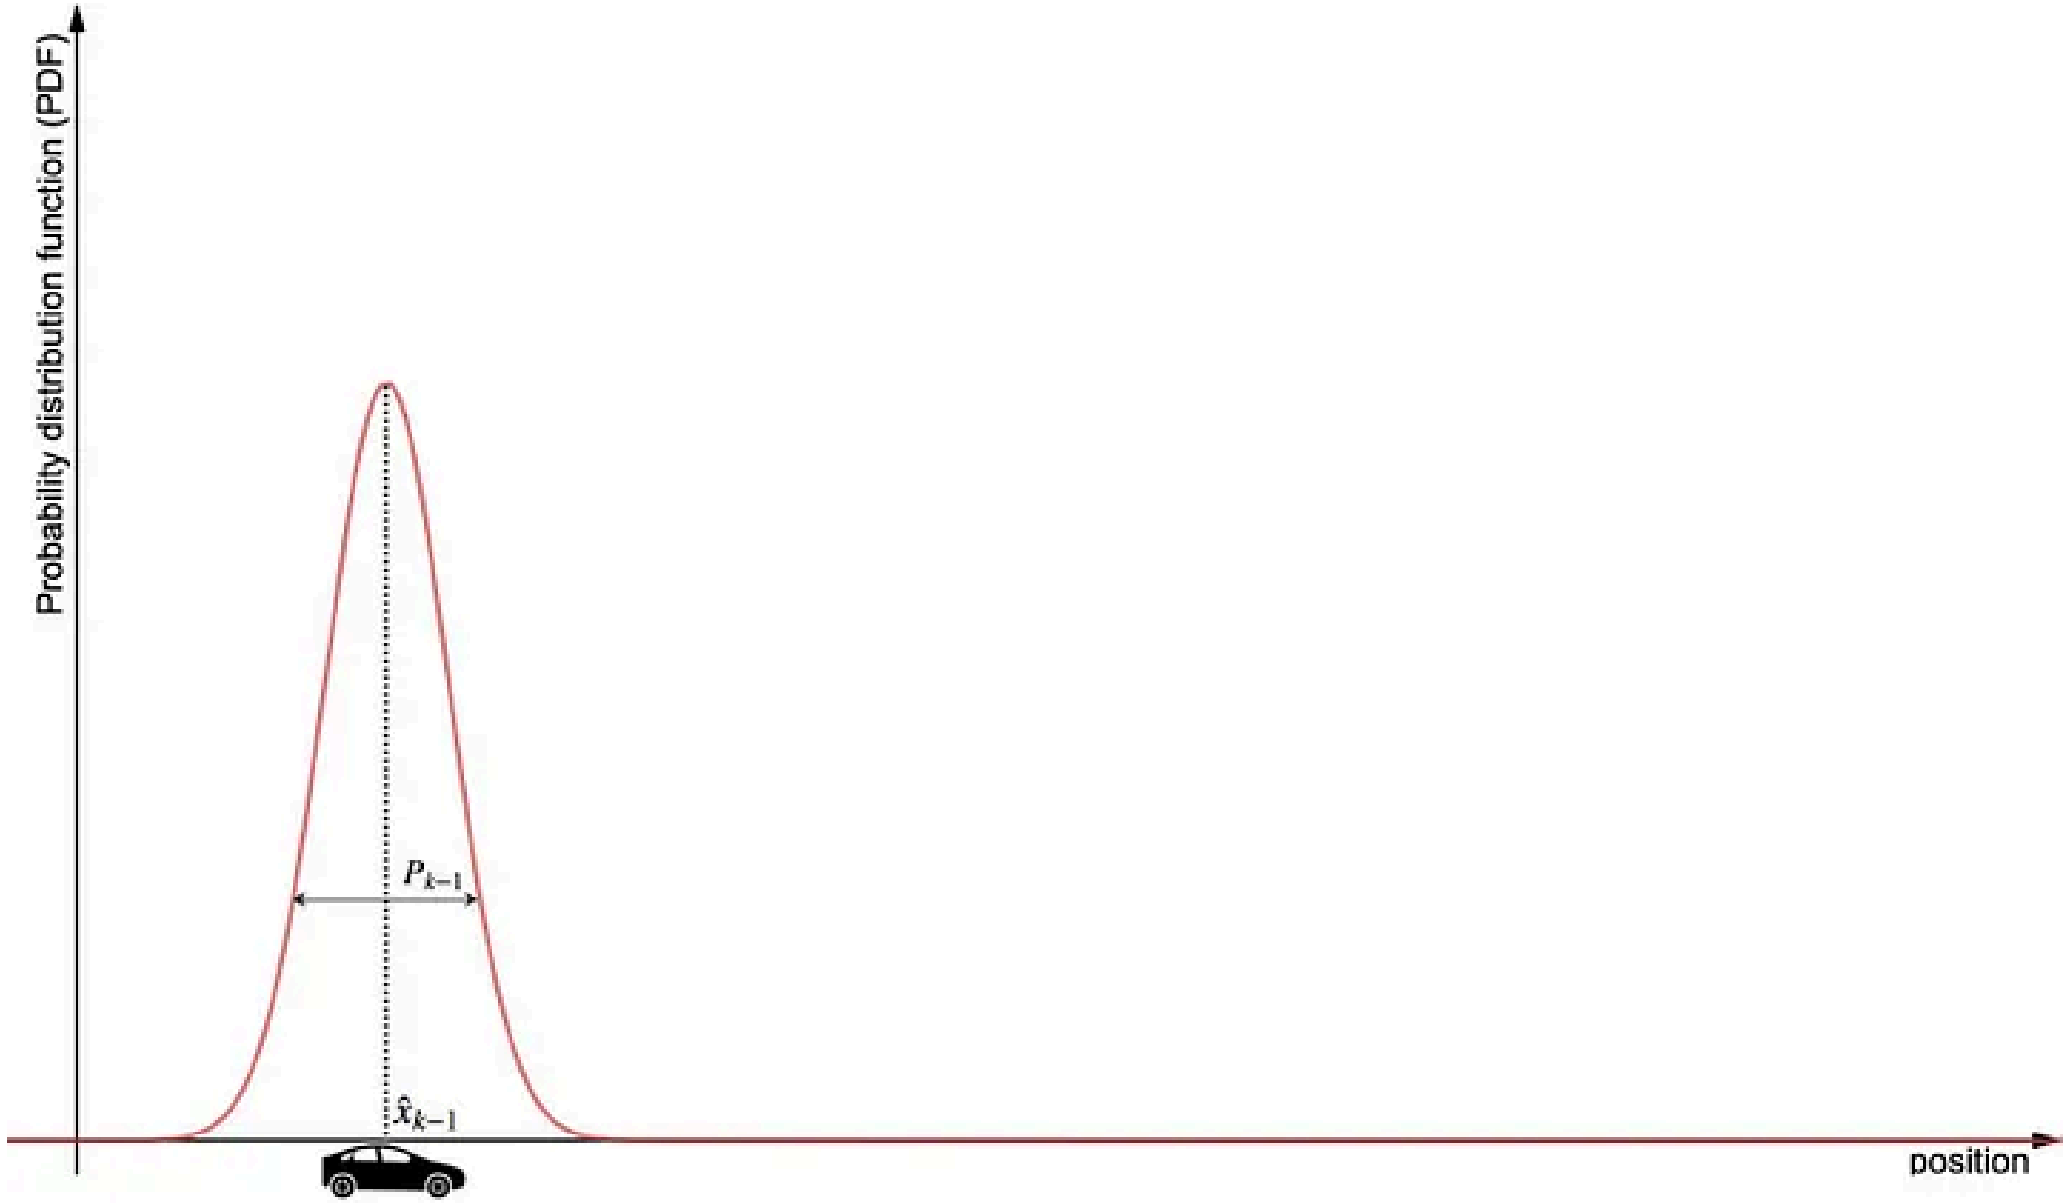
Probability distribution function (PDF)
P_{k-1}
$\hat{x}_{k-1}$
position

Predict 단계 — "다음에 어디 있을까?"

$$\hat{x}_k^- = A\hat{x}_{k-1} + Bu_k$$

$$P_k^- = AP_{k-1}A^T + Q_k$$

- A — **상태 전이 행렬 (물리 법칙을 행렬로 표현)**
  - **등속 운동 가정**: $p_k = p_{k-1} + v_{k-1} \cdot \Delta t, \quad v_k = v_{k-1}$
  - **등속 가정은 단순화** — 실제 로봇은 가속·감속하지만, 매우 짧은 Δt 안에서는 등속으로 볼 수 있어 유효함.
  - 가속도는 Bu_k로 별도 처리, 모르는 외란은 Q_k가 흡수

$$A = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}$$

- Bu_k — **제어 입력 (내가 내린 명령)**
  - 로봇에 가속도 명령 a를 내렸다면:

$$p_k = p_{k-1} + v_{k-1}\Delta t + \frac{1}{2}a\Delta t^2, \quad v_k = v_{k-1} + a\Delta t$$

- **핵심:** Predict 후 P_k^-가 커짐 — 예측만으로는 점점 불확실해짐

Predict Model

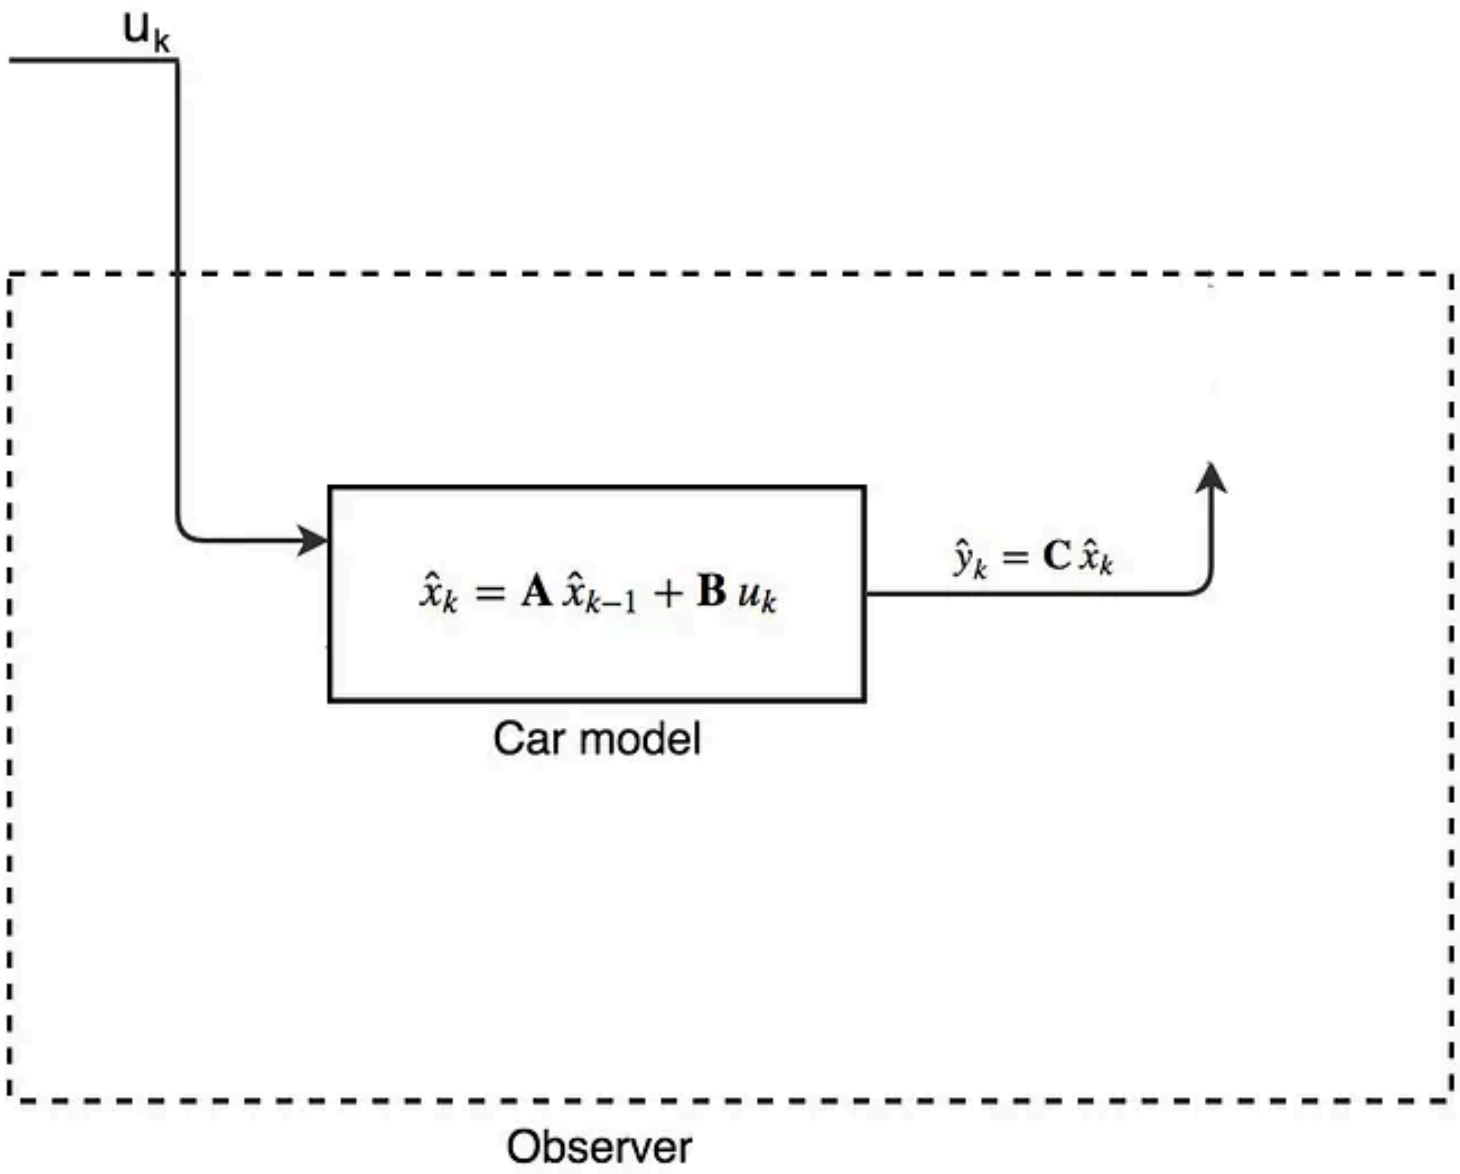

Predict Result

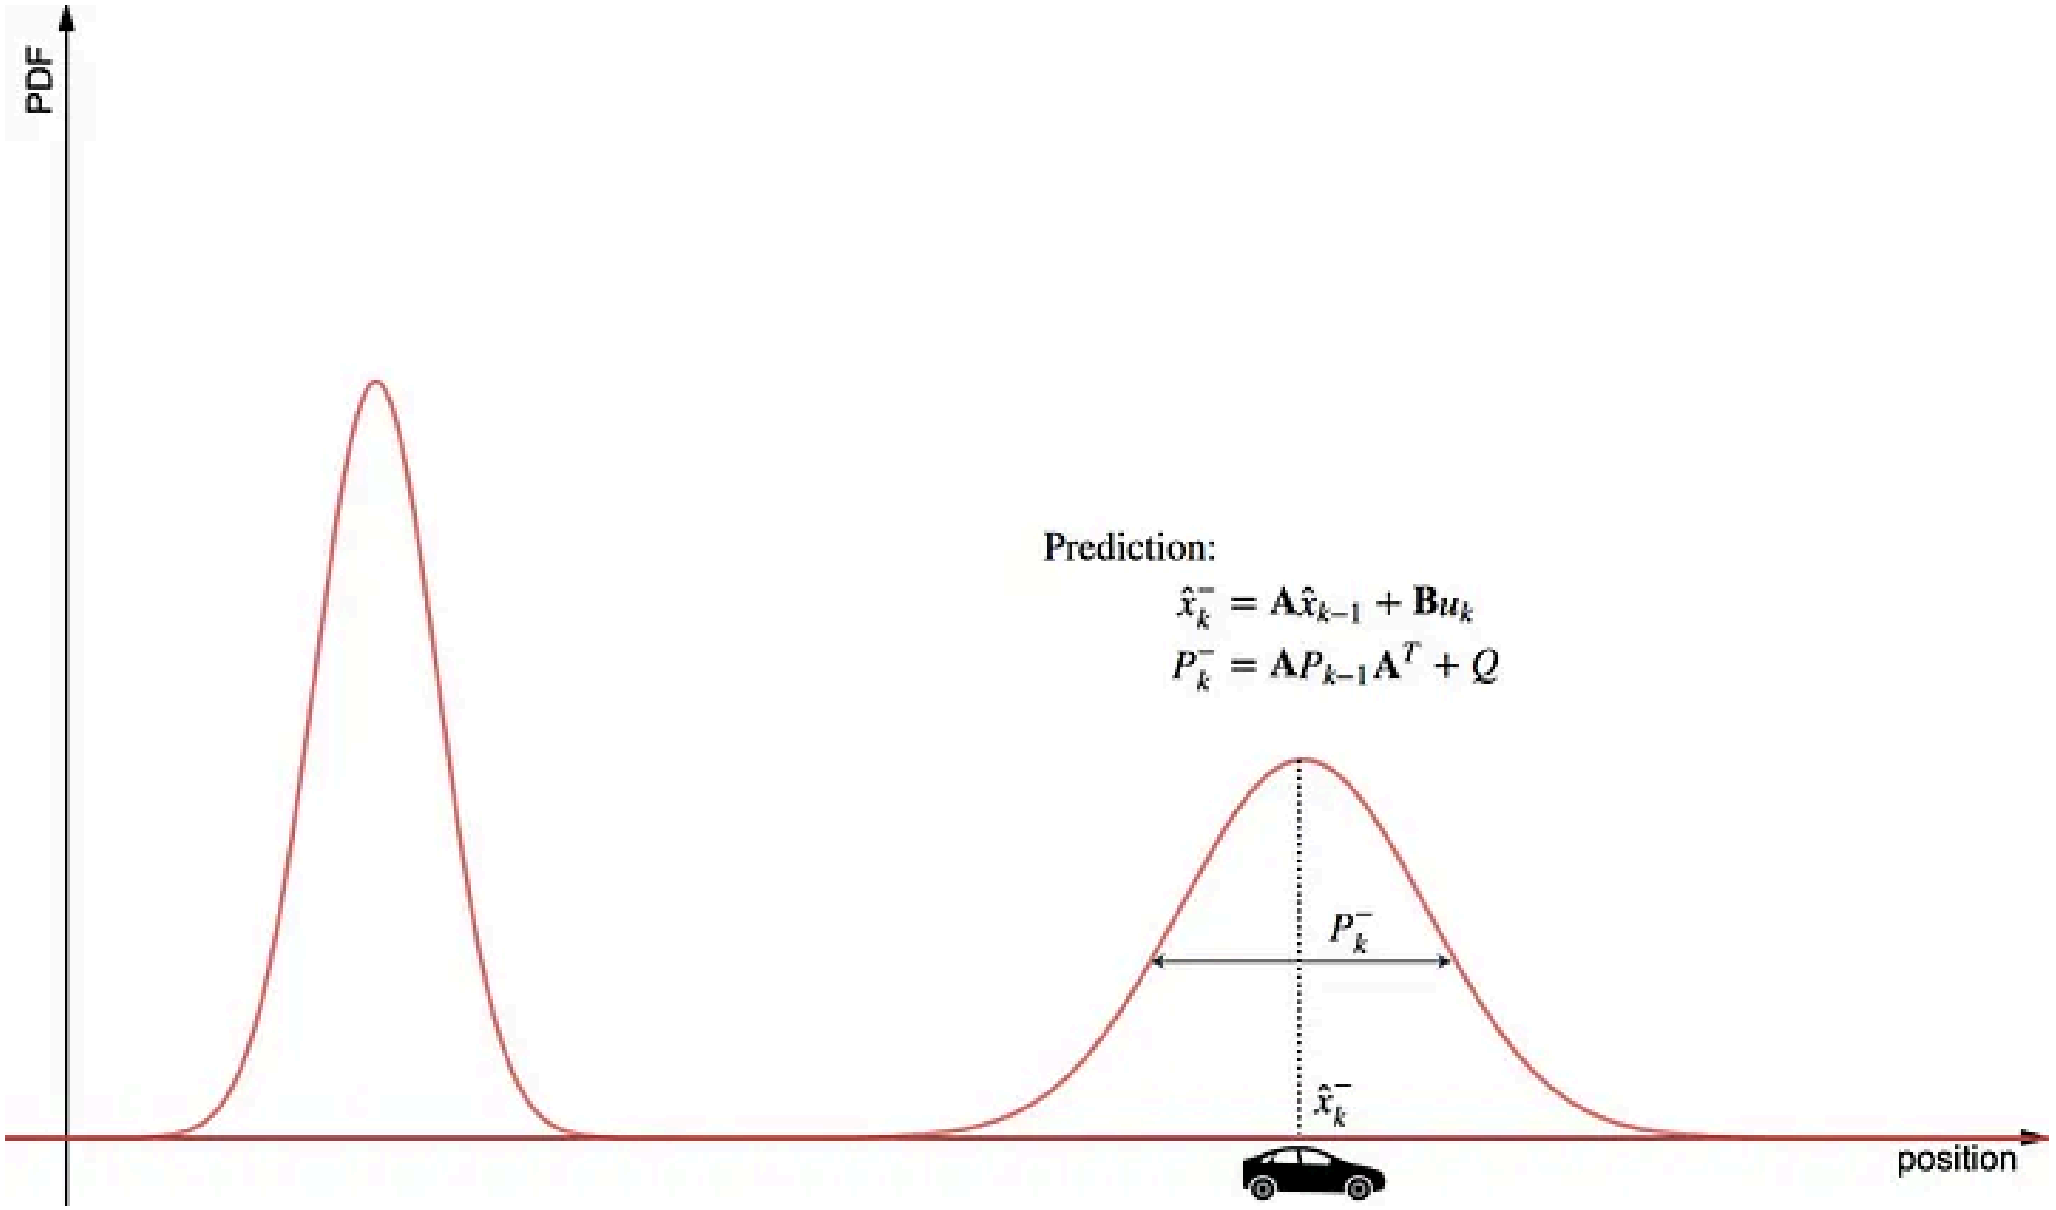

Update 단계 — "센서가 뭐라 했지?"

- C — **센서 행렬: 상태 → 측정 공간으로의 투영**
  - 상태벡터 $[p, v]^T$ 중 **센서가 측정 가능한 성분만 추출**하는 행렬
  - C의 **1** = 해당 상태변수를 측정 가능, **0** = 측정 불가

$$C = \begin{bmatrix} 1 & 0 \end{bmatrix}$$

- **예측 측정값 vs 실제 측정값**

$$\hat{y}_k = C\hat{x}_k^- = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} p \\ v \end{bmatrix} = p \quad \leftarrow \text{모델이 예측한 측정값}$$

$$y_k \quad \leftarrow \text{실제 GPS 센서 측정값}$$

- **둘은 다르다** → 그 차이가 Innovation

$$\text{Innovation} = y_k - \hat{y}_k = y_k - C\hat{x}_k^-$$

Update 직전 - 예측 vs 센서 측정값

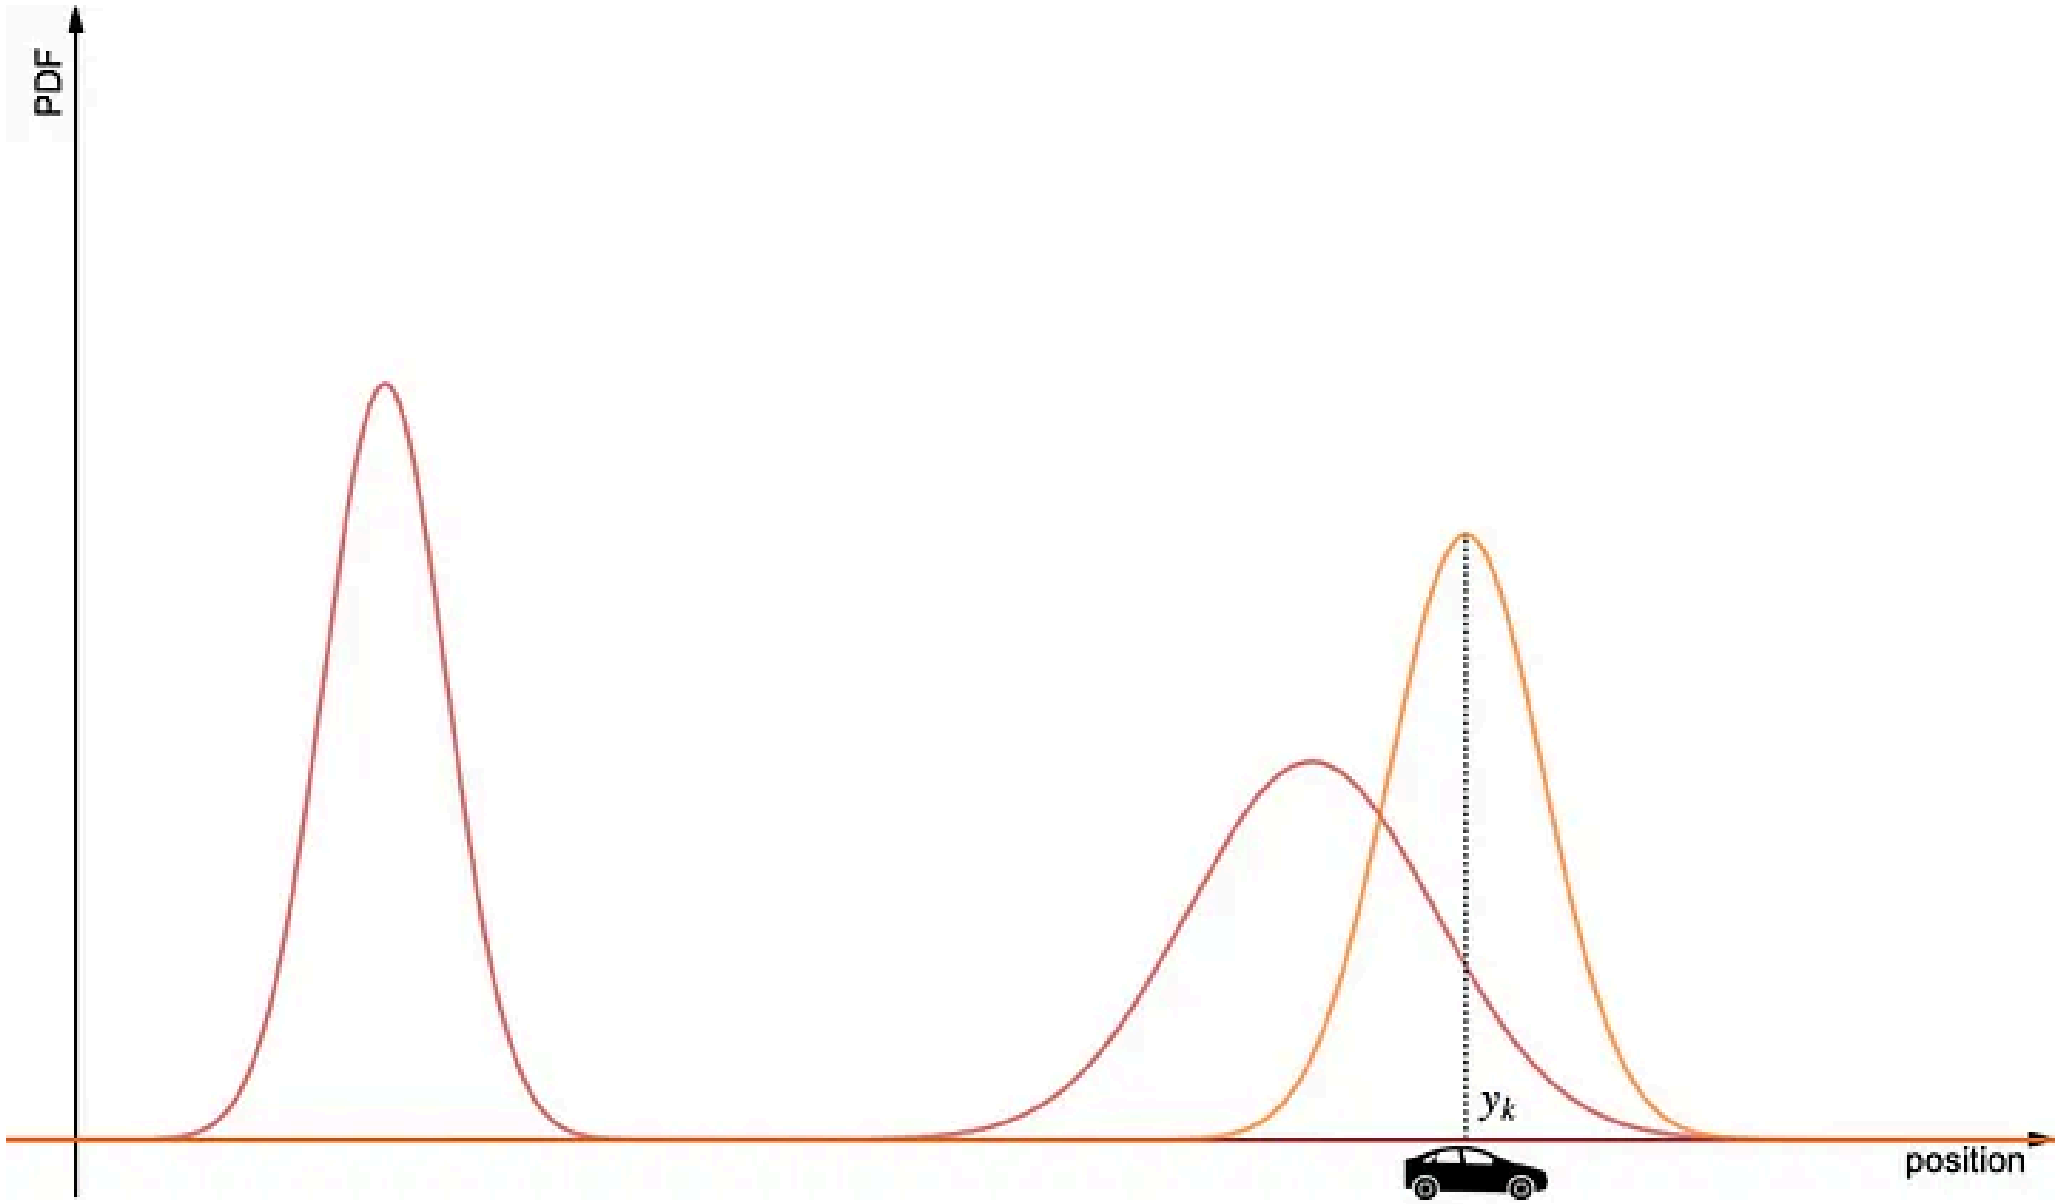

Update 단계 — "칼만 게인"

- **칼만 게인 K_k — 예측 vs 센서, 무엇을 더 믿을까?**
- 행렬에서는 나눗셈이 없음 — $(\ldots)^{-1}$은 **역행렬을 오른쪽에 곱하는 것**

$$K_k = P_k^- C^T \cdot \underbrace{(C P_k^- C^T + R_k)^{-1}}_{\text{역행렬}}$$

상황	**K_k 값**	**의미**
예측이 매우 불확실 ($P^- \gg R$)	$K_k \to 1$	센서를 거의 100% 신뢰
센서가 매우 부정확 ($P^- \ll R$)	$K_k \to 0$	예측을 거의 100% 신뢰
비슷한 수준	$K_k \approx 0.5$	반반

Update 수식 — 보정 및 불확실성 감소

$$\hat{x}_k = \hat{x}_k^- + K_k(y_k - C\hat{x}_k^-)$$

$$P_k = (I - K_k C)P_k^-$$

항	이름	의미
$y_k - C\hat{x}_k^-$	Innovation	예측과 실제 측정의 차이
$K_k \times \text{Innovation}$	보정량	이 차이 중 얼마나 반영할지
$(I - K_k C)P_k^-$	불확실성 감소	K_k 비율만큼 P^-를 줄임

- **P_k^-는 K_k 비율만큼 줄어든다**

```
K_k = 0   →  P_k = (1-0)·P_k⁻ = P_k⁻      (전혀 안 줄어듦 — 센서 무시)
K_k = 0.5 →  P_k = (1-0.5)·P_k⁻ = 0.5P_k⁻ (절반으로 줄어듦)
K_k = 1   →  P_k = (1-1)·P_k⁻ = 0          (이론상 완전히 사라짐)
```

- $K_k = 1$이 되려면 $R = 0$ (완벽한 센서)이어야 함 — 현실에서 완벽한 센서는 없으므로 **P_k는 절대 완전히 0이 되지 않음**

Update Model

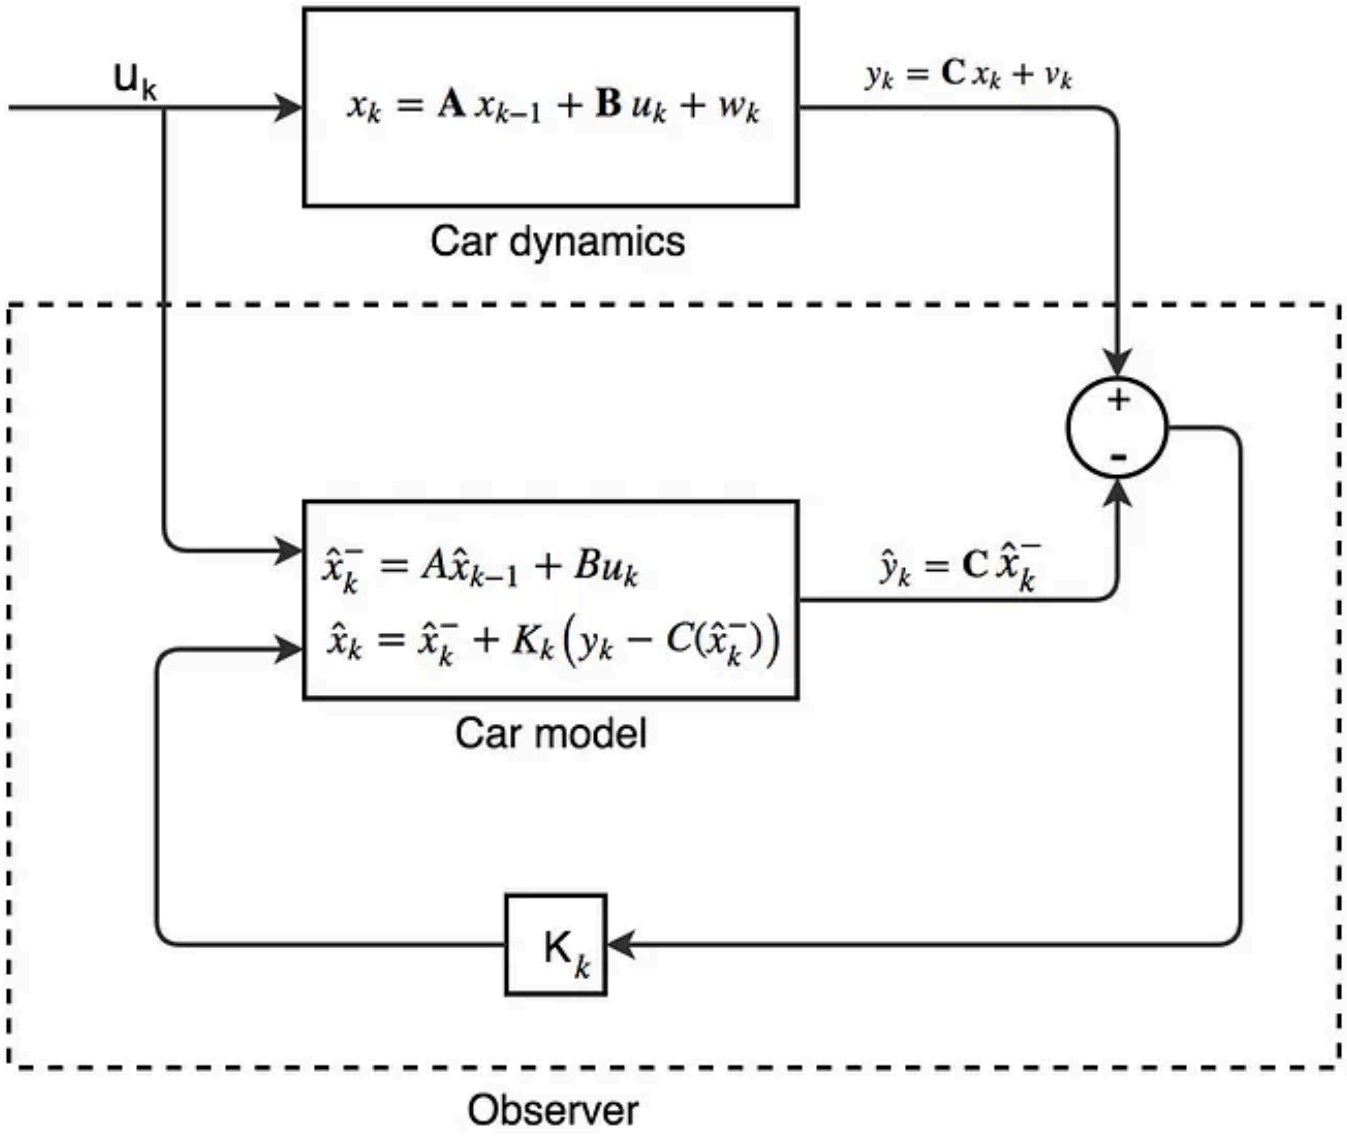

Update Result

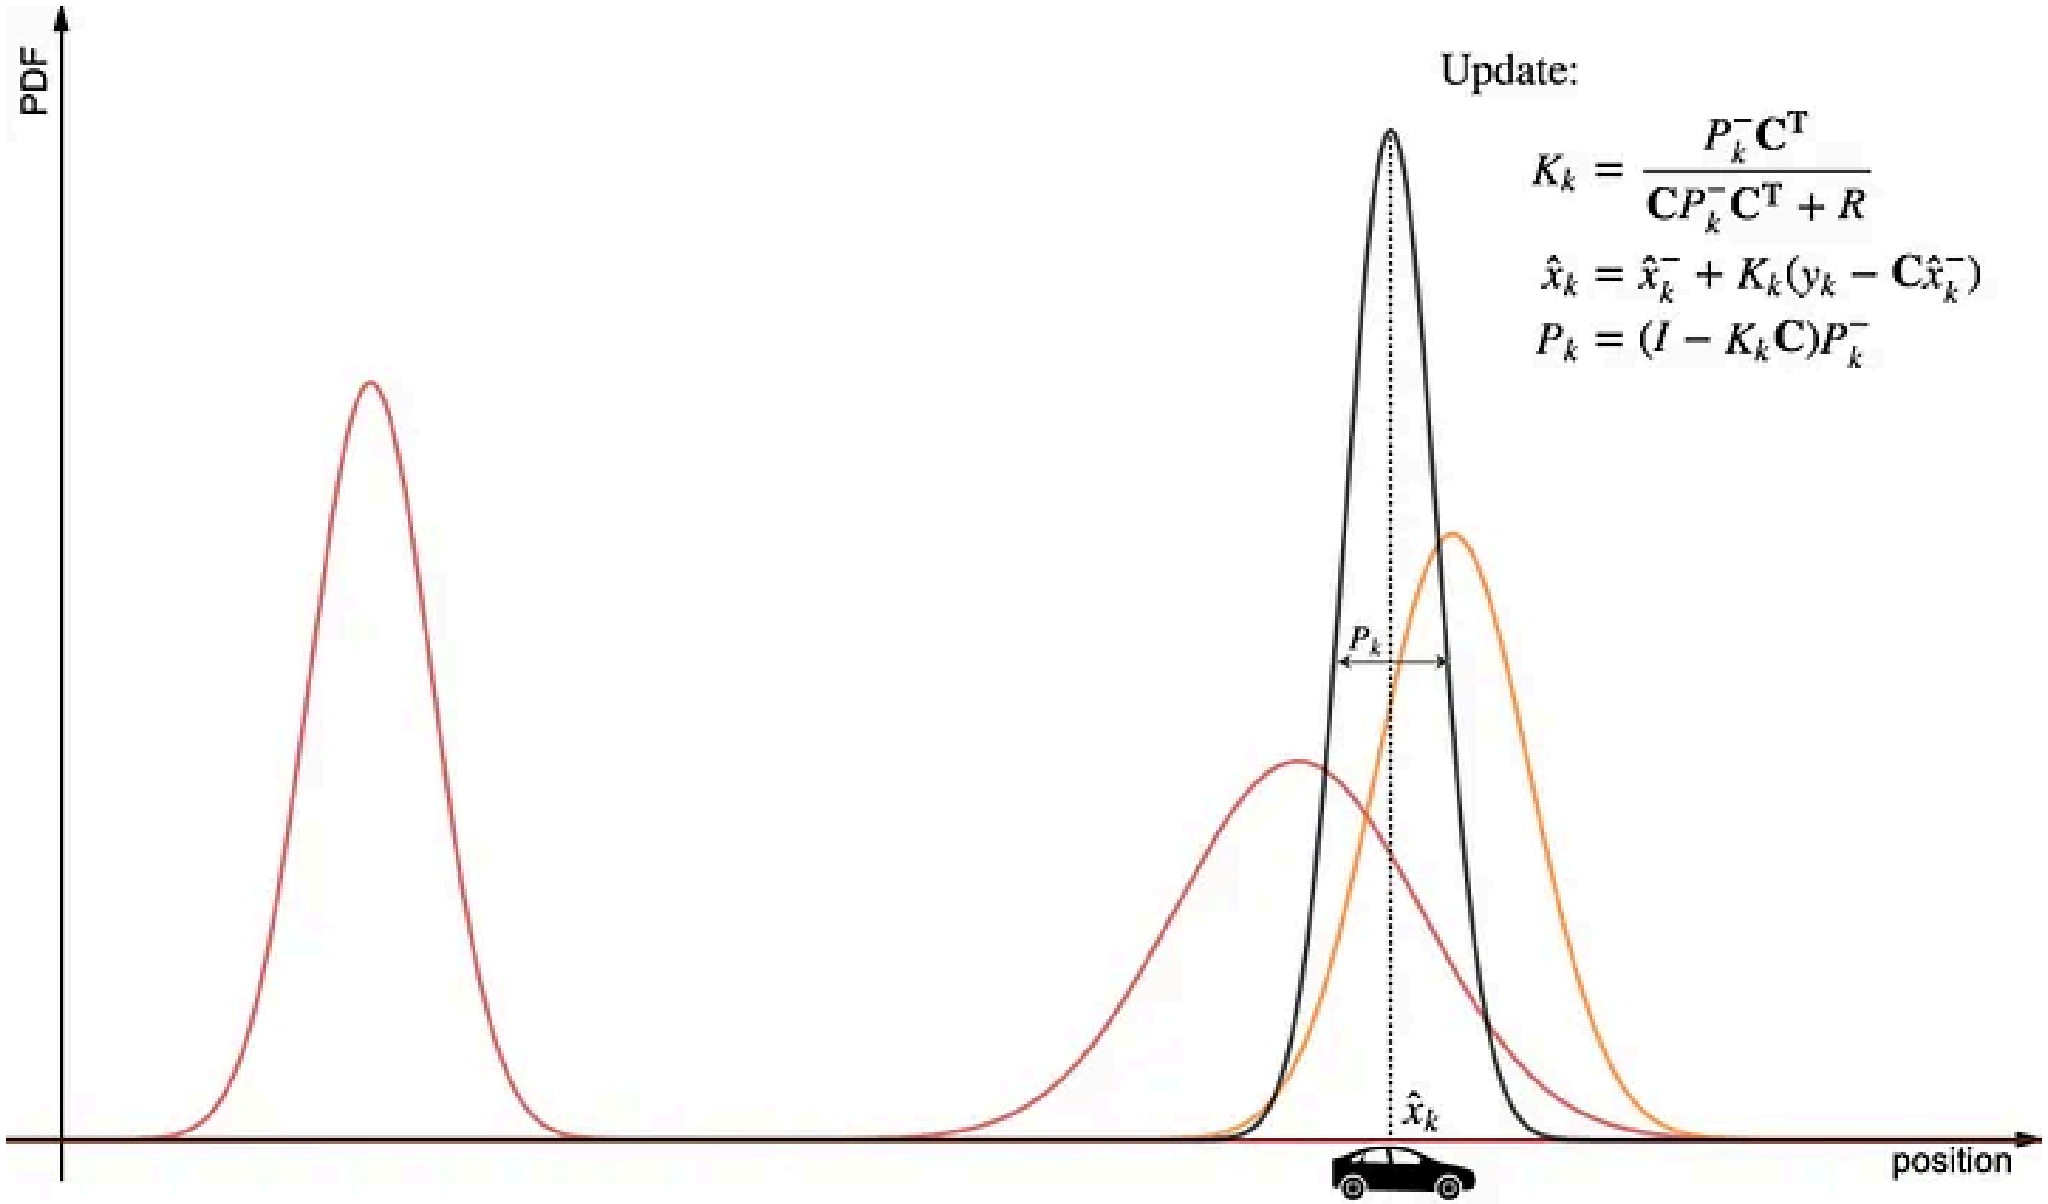

Update:

$$K_k = \frac{P_k^- \mathbf{C}^T}{\mathbf{C} P_k^- \mathbf{C}^T + R}$$

$$\hat{x}_k = \hat{x}_k^- + K_k(y_k - \mathbf{C}\hat{x}_k^-)$$

$$P_k = (I - K_k \mathbf{C}) P_k^-$$

칼만 필터 전체 흐름 — 한눈에 보기 (1/2)

- **초기값 설정** (1회만)

변수	의미	설정 주체
$\hat{x}_0$	초기 위치·속도 추정값	사용자 설정
P_0	초기 불확실성	사용자 설정
A, B, C, Q, R	물리 모델·센서 모델	사용자 설계

칼만 필터 전체 흐름 — 한눈에 보기 (2/2)

- ① Predict — "다음에 어디 있을까?" (모델로 예측)

$$\hat{x}_k^- = A \cdot \hat{x}_{k-1} + B \cdot u_k \qquad \leftarrow \text{운동 모델로 상태 예측}$$

$$P_k^- = A \cdot P_{k-1} \cdot A^T + Q \qquad \leftarrow \text{불확실성 증가}$$

- ② Update — "센서가 뭐라 했지?" (실측값으로 보정)

$$K_k = P_k^- \cdot C^T \cdot (C \cdot P_k^- \cdot C^T + R)^{-1} \qquad \leftarrow \text{예측 vs 센서 가중치}$$

$$\hat{x}_k = \hat{x}_k^- + K_k \cdot (y_k - C \cdot \hat{x}_k^-) \qquad \leftarrow \text{중간값 탐색}$$

$$P_k = (I - K_k \cdot C) \cdot P_k^- \qquad \leftarrow \text{불확실성 감소}$$

- **핵심:** K_k이 0에 가까울수록 예측을, 1에 가까울수록 센서를 더 신뢰
  - P_k^-와 R의 상대적 크기로 자동 결정 — 사람이 직접 정하지 않음
- ① → ② → ① → ② → · · · **반복하며 수렴**

핵심 행렬 한눈에 정리

행렬	이름	한 줄 비유	보통 고정?
A	상태 전이 행렬	"물리 법칙 (등속이면 저기 있겠지)"	✅ 고정
B	제어 행렬	"내가 내린 명령의 효과"	✅ 고정
P_k^- / P_k	추정 공분산	"내 추정이 얼마나 불확실한가"	❌ 매 스텝 변함
Q_k	프로세스 노이즈	"A로 못 담은 외란을 인정"	✅ 보통 고정
C	센서 행렬	"센서가 상태의 무엇을 재는가 (1/0)"	✅ 고정
R_k	센서 노이즈	"센서 신뢰도의 역수"	✅ 거의 고정
K_k	칼만 게인	"P_k^-와 R로 자동 계산되는 가중치"	❌ 매 스텝 계산

- **칼만 필터 설계 우선순위**
  - **1순위 A** — 현실 운동을 얼마나 잘 모델링했는가 (성능의 기반)
  - **2순위 Q** — 모델의 한계를 얼마나 솔직하게 인정했는가 (튜닝의 핵심)
  - **3순위 R** — 실험으로 측정 가능 (비교적 쉬움)
  - **4순위 P_0** — 잘못 설정해도 자동 수렴 (영향 가장 적음)

입문자가 가장 혼란스러워하는 포인트

- **"왜 예측하면 오차가 더 커지나요?"**
  - 예측은 새로운 정보 없이 과거 데이터만으로 추측하기 때문
  - 눈을 감고 걸으면 시간이 지날수록 자신의 위치를 확신하기 어려운 것과 동일

- **"행렬(A, C, Q, R)들의 정체가 뭔가요?"**
  - **A**: 물리 법칙(속도=거리/시간)을 담은 행렬 — 상태 전이
  - **C**: 센서가 측정 가능한 상태변수를 1, 불가능한 것을 0으로 표현
  - **Q**: "내 모델이 얼마나 불완전한지 인정하는 값" — 프로세스 노이즈
  - **R**: "센서 신뢰도의 역수" — 클수록 센서를 덜 믿음

- **"K_k가 1이 되면 P_k가 0이 되는데 괜찮은가요?"**
  - $K_k = 1$은 $R = 0$ (완벽한 센서)일 때만 가능
  - 현실에서 완벽한 센서는 없으므로 P_k는 절대 완전히 0이 되지 않음
  - 칼만 필터는 항상 **"완전한 확신 없이 최선의 추정"** 을 하는 알고리즘

Part 6. 체크리스트

실습 체크리스트

- **오늘 학습한 내용 실습 확인**
  - [ ] **환경 구성**
    - `pip install ultralytics` 명령어로 라이브러리 설치 및 임포트 정상 확인
  - [ ] **모델 테스트**
    - 사전 학습된(Pre-trained) 가중치를 이용해 사진이나 웹캠에서 객체가 박스로 표시되는지 확인
  - [ ] **성능 측정**
    - 로봇 구동 환경에서 초당 프레임 수(FPS)가 실시간 제어에 적합한 수준 **(최소 15~30 FPS 이상)** 인지 확인
  - [ ] **좌표 추출**
    - 검출된 `Boxes` 객체에서 중심점 좌표 계산 → 로봇 제어 데이터로 넘길 준비
  - [ ] **필터 연동**
    - YOLO 검출 결과에 Kalman Filter 적용 → 이동 궤적이 이전보다 부드러워졌는지 시각적으로 비교